Лабораторная работа 2

Базовый RAG: проверка научных утверждений

Цель. Проверить пользу поиска по SciFact и определить, где теряется свидетельство: поиск, сборка контекста или ответ модели.

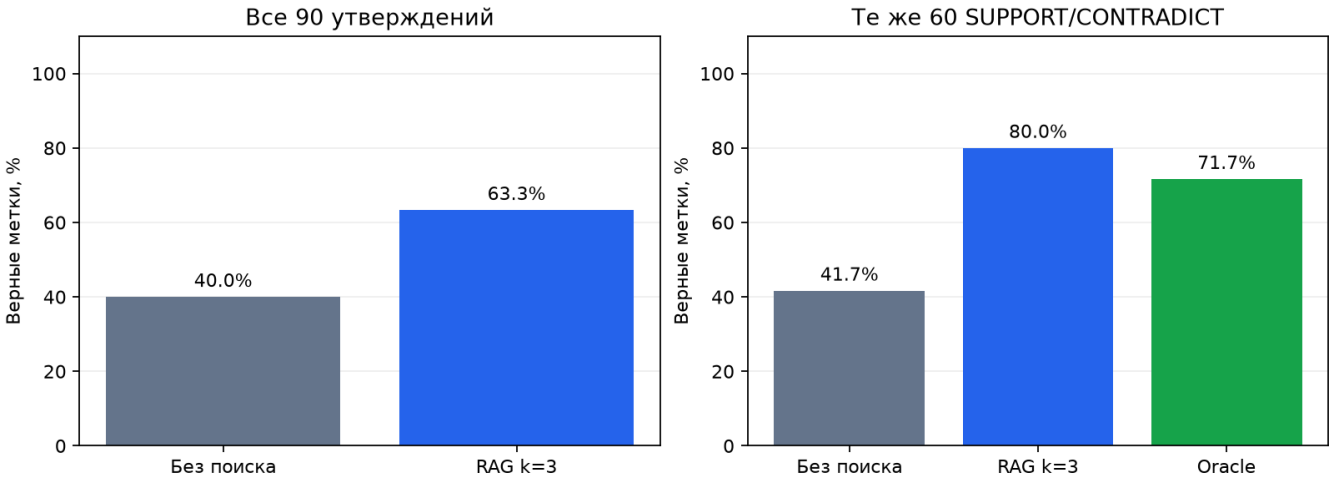
Условия. 5183 аннотации; dev 90 (30 на класс), holdout 210 не использован. BGE-small-en-v1.5: 384 числа, 512 токенов, нормированные векторы; обрезано 455 аннотаций (8.8%). Qwen3-4B-Instruct-2507 Q4_K_M на CPU Ryzen 7 3700X, 8 потоков, llama.cpp b12110; температура 0, seed 42, ответ до 128 токенов. Промпт до 2048 токенов после шаблона; structured outputs и проверка ссылок.

Прогноз до запуска. Без поиска труднее CONTRADICT; RAG исправит 10-20 ответов, но может испортить 3-10. Oracle ожидается лучше на одинаковых 60 примерах. При росте k поиск не ухудшится, но качество ответов может ухудшиться из-за бюджета и лишнего текста.

1. Без поиска, с поиском и с эталоном

Режим	Accuracy /90	Recall SUPPORT	Recall CONTRADICT	Recall NOINFO	Ссылка /60
LLM-only	40.0%	23.3%	60.0%	36.7%	не требуется
RAG k=3	63.3%	70.0%	90.0%	30.0%	65.0%

Попарно LLM-only → RAG: исправлено **28**, испорчено **7**; изменение Accuracy +23.3 п.п. Минимальная полнота LLM-only — у SUPPORT; прогноз о наиболее трудном классе не подтвердился. Ошибки вызова/разбора не исключались; таких ответов во всех 420 вызовах: 13.



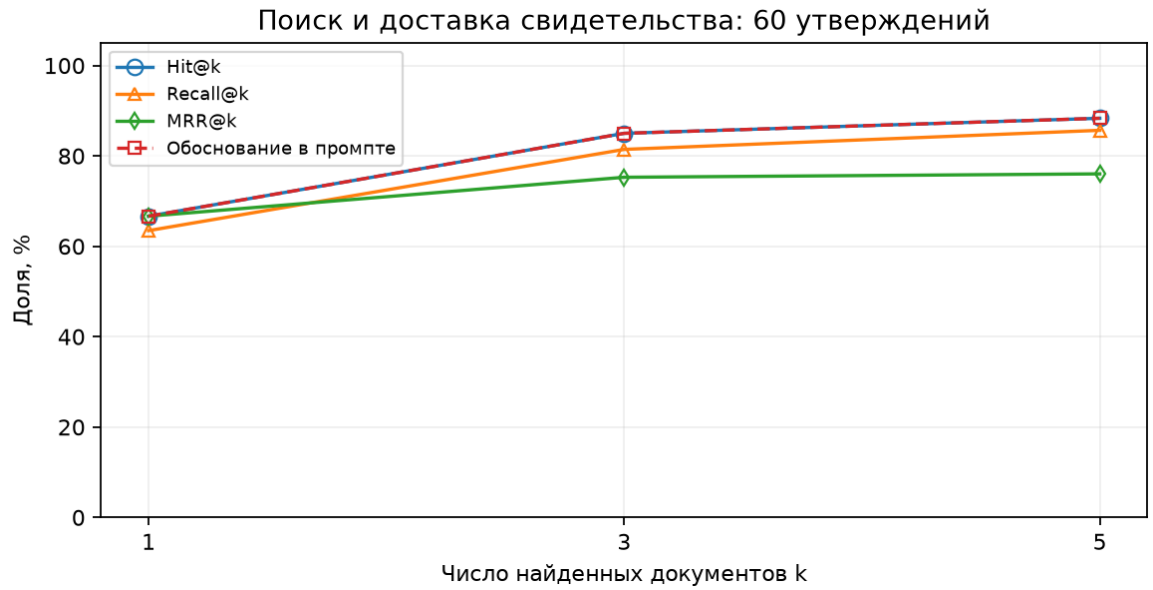
Oracle получает одно полное эталонное обоснование, без метки. На тех же 60: LLM-only 41.7%, RAG 80.0%, Oracle 71.7%. Oracle не является гарантированной верхней границей: он получает только одно обоснование, без остального текста. В этом запуске он уступил RAG; конкретные причины разницы отдельно не изолировались.

2. Сколько документов передавать

Для k=1,3,5 использованы начала одной top-5 выдачи. Первая таблица: 60 SUPPORT/CONTRADICT, включая средние документы/токены. Accuracy: все 90. k=3 повторно не запускался.

k	Hit@k	Recall@k	MRR@k	Обоснование /60	Документов, ср.	Токенов, ср.
1	66.7%	63.5%	66.7%	66.7%	1.00	536.8
3	85.0%	81.4%	75.3%	85.0%	2.97	1287.3
5	88.3%	85.7%	76.0%	88.3%	4.58	1812.5

k	Accuracy /90	Верная ссылка /60	Исправлено к k=3	Испорчено к k=3
1	60.0%	48.3%	5	8
3	63.3%	65.0%	-	-
5	64.4%	68.3%	5	4



Интерпретация. При k=3→5 Recall изменился с 81.4% до 85.7%, а доставка обоснования — с 85.0% до 88.3%. У 5 из 90 промпт не изменился: бюджет исчерпан раньше новых документов. Изменение ответа при добавлении текста не доказывает конкретный механизм ошибки; проверяем отдельные случаи.

Проверка бюджета без генерации. Прогноз: при 1024 токенах доставка не вырастет. Получено 51/60 при 2048 и 49/60 при 1024. Сохранены пересобранные контексты; качество ответов при 1024 не измерялось.

В MLflow оставлены три метрики: accuracy, correct_citation, evidence_in_prompt; Step = k, значения 0-1. Оформленные графики находятся в analysis. Разные знаменатели Accuracy и ссылок нельзя вычитать как число ошибок.

3. Где возникают ошибки

1. ID 314: Поиск не нашёл свидетельство

Deamination of cytidine to uridine on the minus strand of viral DNA results in catastrophic G-to-A mutations in the viral genome. **Эталон: SUPPORT.**

Нужно: 4347374: [3, 5]. Найдено (score): 544971 (0.757), 2638387 (0.741), 34498325 (0.719).

Переданы предложения: 544971: [0, 1, 2, 3]; 2638387: [0, 1, 2, 3, 4, 5, 6, 7]; 34498325: [0, 1, 2, 3, 4, 5, 6, 7]. Всего 1180 токенов.

Сырой ответ: { "label": "SUPPORT", "doc_id": "2638387", "sentences": [4, 2] }. Нужного документа нет в top-3. Потеря на этапе поиска. Метка верна, но ссылка не совпадает с эталонным обоснованием.

2. ID 56: Модель ошиблась при наличии свидетельства

APOE4 expression in iPSC-derived neurons increases AlphaBeta production and tau phosphorylation causing GABA neuron degeneration. **Эталон: SUPPORT.**

Нужно: 4709641: [1]. Найдено (score): 4709641 (0.867), 13814480 (0.796), 35777860 (0.784).

Переданы предложения: 4709641: [0, 1, 2, 3, 4, 5]; 13814480: [0, 1, 2, 3, 4, 5]; 35777860: [0, 1, 2, 3, 4]. Всего 1025 токенов.

Сырой ответ: { "label": "CONTRADICT", "doc_id": "4709641", "sentences": [1] }. Полное эталонное обоснование передано. Ошибка на этапе ответа модели; одного улучшения поиска недостаточно.

3. ID 554: Ошибка на NOINFO

Immune complex triggered cell death leads to extracellular release of neutrophil protein HMGB1. **Эталон: NOINFO.**

Нужно: нет. Найдено (score): 9878167 (0.760), 43054703 (0.751), 381602 (0.750).

Переданы предложения: 9878167: [0, 1, 2, 3, 4, 5, 6]; 43054703: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11]; 381602: [0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10]. Всего 1211 токенов.

Сырой ответ: { "label": "CONTRADICT", "doc_id": "43054703", "sentences": [7] }. В разметке нет обоснования, но модель выбрала другую метку или нарушила формат. Это ошибка относительно эталона SciFact; отсутствие разметки не доказывает ложность утверждения.

4. ID 1132: Поиск не нашёл свидетельство

TCR/CD3 microdomains are a required to induce the immunologic synapse to activate T cells. **Эталон: SUPPORT.**

Нужно: 33499189: [3, 4]. Найдено (score): 15972906 (0.818), 18834078 (0.793), 994800 (0.781).

Переданы предложения: 15972906: [0, 1, 2, 3, 4, 5, 6]; 18834078: [0, 1, 2, 3, 4, 5, 6]; 994800: [0, 1, 2, 3, 4, 5, 6]. Всего 941 токенов.

Сырой ответ: { "label": "CONTRADICT", "doc_id": "15972906", "sentences": [3] }. Нужного документа нет в top-3. Потеря на этапе поиска.

Не встретились: Свидетельство не поместилось. Показаны другие реальные ошибки.

Вывод. Лучший результат среди проверенных k: k=5, Accuracy 64.4%. Найти документ, передать обоснование и правильно ответить — три разные проверки. Вывод ограничен данным dev и одной моделью; holdout сохранён для ЛР3.

Воспроизводимость и кодогенерация. Код подготовлен с помощью Codex. Проверены тесты метрик/парсера, близость одинаковых текстов, лимиты и совпадение токенов с usage сервера. Источник SciFact, SHA-256, разбиение и паспорт индекса сохранены. Полные тексты четырёх случаев — error_cases.md; ответы к защите — defense.md. Исходники: experiment.py, evaluation.py, rag.py, build_index.py, analyze.py, make_report.py.

Источники: задание ЛР2; официальный SciFact (allenai/scifact); карточка BAAI/bge-small-en-v1.5. Запуск 20261106_183751; ревизия BGE 5c38ec7c405e; полный хеш матрицы и ревизия в index/passport.json.